Phân loại đa bệnh lý võng mạc bằng Edge AI hợp nhất

1. Đặt vấn đề

- Câu hỏi nghiên cứu: Làm thế nào để đưa mô hình học máy phân loại đa bệnh lý võng mạc trực tiếp xuống các thiết bị biên (Edge AI) có tài nguyên hạn chế, giải quyết được thách thức về nhiễu và phân phối mẫu mất cân bằng của tập dữ liệu đa nhãn ODIR-5K, đồng thời đảm bảo thời gian phản hồi nhanh chóng mà không phụ thuộc vào phần cứng đồ họa mạnh mẽ?
- Ý nghĩa lâm sàng: Phát hiện sớm các bệnh lý về mắt (như võng mạc tiểu đường, tăng nhãn áp, đục thủy tinh thể) giúp ngăn ngừa suy giảm thị lực và mù lòa. Hỗ trợ triển khai hệ thống chẩn đoán độc lập tại các cơ sở y tế địa phương hoặc nơi thiếu thốn hạ tầng công nghệ, không yêu cầu kết nối mạng liên tục, giúp tiết kiệm chi phí và khắc phục sự phụ thuộc vào kinh nghiệm chuyên môn thủ công của bác sĩ.
- Dataset: Tập dữ liệu ODIR-5K (Ocular Disease Intelligent Recognition 2019) bao gồm 10.000 ảnh màu đáy mắt từ 5.000 bệnh nhân, tích hợp thông tin nhân khẩu học (tuổi, giới tính) và nhãn chẩn đoán. Đặc thù và cũng là thách thức lớn nhất của bộ dữ liệu này là chứa nhiều vùng nhiễu nền đen dư thừa và sự chênh lệch số lượng mẫu cực kỳ lớn giữa các nhóm bệnh lý (mất cân bằng nhãn).

2. Y văn đối chiếu (Các nghiên cứu tiêu biểu trên ODIR-5K)

2.1. Đọc kỹ thiết lập thực nghiệm y văn trước khi so sánh:

- Nghiên cứu của M. A. Rodríguez và cộng sự: Đề xuất kiến trúc C-Tran (kết hợp DenseNet161 và Transformer Encoder), áp dụng kỹ thuật tái lấy mẫu LP ROS và Label Mask Training để xử lý mất cân bằng. Dù đạt AUC 0,962, mô hình này vẫn cồng kềnh, nhận diện kém ở lớp bệnh hiếm gặp và chưa được kiểm nghiệm triển khai trên phần cứng nhúng với ràng buộc thời gian thực.
- Nghiên cứu của P. Thaware và cộng sự: Dùng mô hình EfficientNet-B0 tối ưu qua TFLite tích hợp trên Raspberry Pi 5, đạt tốc độ suy luận 5 giây/ảnh.
- Các nghiên cứu về Học liên kết (Federated Learning - FL): Ứng dụng FL phân tán kết hợp với Vision Transformer hay mã hóa đồng cấu nhằm giải quyết tốt khâu bảo mật dữ liệu. Tuy nhiên, việc tối ưu hóa mô hình đa nhãn sao cho đủ nhẹ để chạy độc lập (offline) trên thiết bị Edge đối với dữ liệu nhiễu như ODIR-5K vẫn là một khoảng trống cần hoàn thiện.

3. Phương pháp

- Chia dữ liệu: Áp dụng thuật toán Iterative Stratification trên file nhãn ODIR-5K chia tỷ lệ 70/15/15, random_state=42 -> Train 70%, Val 15%, Test 15% - giữ nguyên tỷ lệ phân bố của cả 8 nhãn bệnh lý đồng đều giữa các tập, tránh rò rỉ dữ liệu giữa 2 mắt của cùng bệnh nhân.
- Tiền xử lý ảnh: Crop Contour (OpenCV) tự động tìm viền nhãn cầu loại bỏ phần viền đen thừa → Resize 224×224 → Normalize theo ImageNet (mean/std).
- Tăng cường dữ liệu (chỉ áp dụng trên Train): RandomRotate ($\pm 15^{\circ}$), lật ảnh, ColorJitter điều chỉnh độ sáng/tương phản để tăng tính đa dạng cho các nhóm bệnh lý ít mẫu; batch ảnh sau augment được kiểm tra trực quan đảm bảo không méo mó giải phẫu võng mạc
- Data Pipeline: Xây dựng custom PyTorch Dataset và DataLoader đọc ảnh theo batch, xuất tensor ảnh $3 \times 224 \times 224$ kèm multi-hot vector nhãn 8 chiều.
- Mô hình Baseline: EfficientNet-B0 (pre-trained ImageNet), sửa lớp Linear cuối thành 8 outputs, sử dụng BCEWithLogitsLoss kết hợp kích hoạt Sigmoid độc lập cho bài toán phân loại đa nhãn.

- Huấn luyện & Giám sát: Tích hợp Weights & Biases (W&B) theo dõi loss/metrics theo thời gian thực; đánh giá bằng Macro F1, Micro F1, AUC trên từng nhãn bệnh; lưu checkpoint trọng số .pth tốt nhất trên tập Val.

4. Kết quả và phân tích chuyên sâu
5. Khả năng giải thích lâm sàng
6. Hạn chế